

# Aprendizagem Guiada para Análise Morfossintática usando Redes Neurais Recursivas

---

Marcos Vinícius Treviso  
marcosvtreviso@gmail.com

Orientador: Fábio Natanael Kepler  
Trabalho de Conclusão de Curso I

8 de julho de 2015

Universidade Federal do Pampa

# Agenda da apresentação

Introdução

Fundamentação

Trabalhos relacionados

Metodologia


Cronograma

Referências

- *Part-of-speech* (POS) Tagging
- O problema
- Objetivos


É conhecido em Processamento de Linguagem Natural (PLN) como o ato de classificar uma palavra pertencente a um conjunto de textos em uma classe gramatical.

- Acurácia
- Aplicações
- Desafios



# O problema

- Há muita ambiguidade no português
- Estratégia trivial não é eficaz
- É necessário analisar o contexto
- Aprendizado de máquina




# Objetivos

- Novo método para POS Tagging
  - A princípio para o português brasileiro
- Estado da arte
  - Novas técnicas
  - Novas abordagens
- Análise de eficiência
  - Acurácia
  - Tempo de treinamento

- Aprendizado de máquina
- Corpus
- Representação das palavras
- Redes neurais
- Aprendizagem profunda

# Aprendizado de máquina

- Aprendizado supervisionado
  - Regressão
  - Classificação
- Aprendizado não supervisionado





- Coleções de textos agrupados
- Anotação gramatical manual
- *Cópus* para o português brasileiro:

Cópus	Sentenças	Palavras	Classes gramaticais
Mac-Morpho original	53,374	1,221,465	41
Mac-Morpho revisado <sup>1</sup>	49,932	945,958	26
Tycho Brahe	55,932	1,541,654	265

- Por que não combiná-los?

1. Revisado em: (FONSECA; ROSA; ALUÍSIO, 2015).

# Representação das palavras

- Dados de entrada (*features*)
- Vetores reais valorados em um espaço multidimensional (*word embeddings*)
- Mais desempenho de aplicações em PLN e menos engenharia de *features*
- Conseguem capturar informações sintáticas e semânticas
- Geradas de maneiras diferentes dependendo da técnica utilizada


# Técnicas para geração de *word embeddings*

- Matriz de coocorrência
- *Neural Language Model* (NLM): Através de redes neurais
- *Hyperspace Analogue to Language* (HAL): Matriz de coocorrência com um método de decomposição (Escalamento Multidimensional)
- Modelação *Skip-Gram* (SG): Previsão de palavras vizinhas num conjunto de tamanho finito.
- *Global Vectors* (GloVe): Razão das probabilidades na matriz de coocorrência em relação ao contexto de uma outra palavra do vocabulário.

$$W : \text{word} \rightarrow \mathbb{R}^n$$


# Técnicas para geração de *word embeddings*

- Palavras similares estão próximas.




Fonte: Turian, Ratinov e Bengio (2010)

- Simulação do cérebro humano
- Unidades de ativação:  $a_i^{(j)}$
- Pesos:  $\theta^{(j)}$
- Função de ativação:  $g(z)$
- Parâmetros:  $z^{(j+1)} = \theta^{(j)} a^{(j)}$



# Redes neurais


- Processo de aprendizagem:



Fonte: Ng (2015)

# Redes neurais


- Processo de aprendizagem:



Fonte: Ng (2015)

# Aprendizagem profunda

- Muitas tranformações não lineares
- Objetivo de aprender automaticamente boas *features*
- Crescimento do desempenho computacional
- Redes neurais com múltiplas camadas



Adaptado de: Bengio, Goodfellow e Courville (2015)



- Escopo do português brasileiro

<b>Autores</b>	<b>Modelo</b>	<b>Representação das palavras</b>	<b>Cópus</b>
Kepler (2005)	VLMM	Sequência de caracteres	Tycho Brahe
Santos e Zadrozny (2014)	Redes neurais profundas	Vetores (CharWNN)	Tycho Brahe; Mac-Morpho
Fonseca, Rosa e Aluísio (2015)	Redes neurais	Vetores (NLM, HAL, SG)	Tycho Brahe; Mac-Morpho
Este trabalho	Redes neurais recursivas	Vetores Vetores (NLM, SG, GloVe)	Tycho Brahe; Mac-Morpho

- Estado da arte com 97,57% de acurácia para todas palavras (FONSECA; ROSA; ALUÍSIO, 2015)
- Estado da arte com 94,34% de acurácia para palavras fora do vocabulário (FONSECA; ROSA; ALUÍSIO, 2015)

- Representação das palavras
- Pontuações para estrutura gramatical
- Treinamento

# Representação das palavras

- Técnicas:
  - NLM
  - SG
  - GloVe

$$w_i \in \omega \rightarrow v_i \in \mathbb{R}^d$$

$$c_i \in \gamma \rightarrow z_i \in \mathbb{R}^d$$

- Capitalização
- Prefixos

# Pontuações para estrutura gramatical

- Janela de palavras com tamanho  $t$ :

$$V_n = \{v_{n-(t-1)/2}, \dots, v_n, \dots, v_{n+(t-1)/2}\}$$

- Pontuações para estrutura gramatical:

$$s_c(V_n)$$


$$A_{c,d,e}$$

- Pontuação final para  $w_i^t$  dado  $c_1^t$ :

$$S(w_1^t, c_1^t) = \sum_{k=1}^t \left( \arg \max_{1 \leq i \leq t, i \notin Q} (s_{c_i}(V_i) + A_{c_{i-1}, c_i, c_{i+1}}) \right)$$

# Treinamento

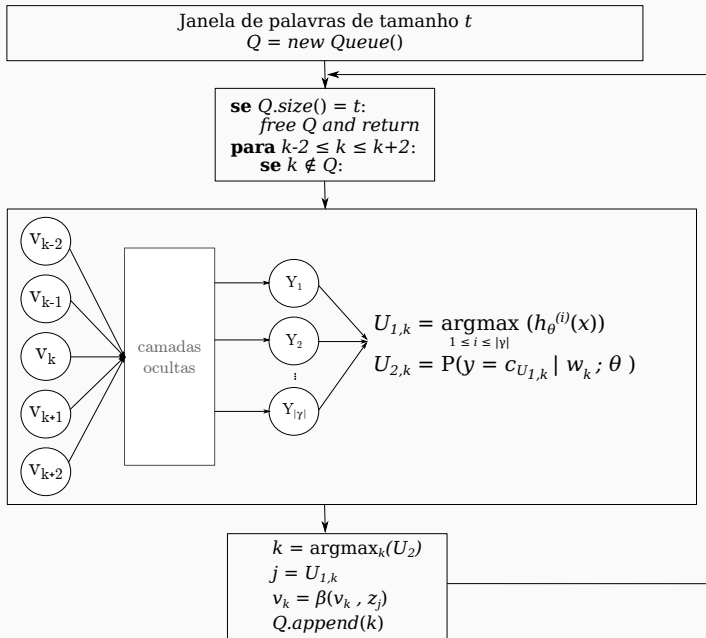
- Treinamento supervisionado
- Rede neural recursiva
- Aprendizagem guiada por palavras mais fáceis (SHEN; SATTA; JOSHI, 2007)



- Composição dos vetores:

$$v_n = v_n + z_c$$

# Treinamento



- Ajustamentos feitos para maximizar:

$$\sum_{(w_1^t, c_1^t) \in \phi} P(c_1^t | w_1^t, \theta)$$

- Função de custo:

$$J(\theta) = \log \left( \sum_{u_1^t \in \gamma^t} e^{S(w_1^t, u_1^t)} \right) - S(w_1^t, c_1^t)$$

- Gradiente Descendente, Gradiente Descendente Estocástico, Adagrad, Adadelta, etc. (BENGIO; GOODFELLOW; COURVILLE, 2015)

# Cronograma

A1 - Implementação do modelo neural recursivo

A2 - Treinamento do modelo

A3 - Avaliação dos resultados obtidos

A4 - Escrita da monografia

	Agosto	Setembro	Outubro	Novembro	Dezembro
<b>A1</b>	X	X	X		
<b>A2</b>		X	X	X	
<b>A3</b>			X	X	X
<b>A4</b>				X	X



BENGIO, Y.; GOODFELLOW, I. J.; COURVILLE, A. Deep learning. Book in preparation for MIT Press. 2015. Disponível em:

<<http://www.iro.umontreal.ca/~bengioy/dlbook>>. 16, 23

FONSECA, E. R.; ROSA, J. L. G.; ALUÍSIO, S. M. Evaluating word embeddings and a revised corpus for part-of-speech tagging in portuguese. *Journal of the Brazilian Computer Society*, Springer, v. 21, n. 1, p. 1–14, 2015.

9, 17

KEPLER, F. N. *Um etiquetador morfo-sintático baseado em cadeias de Markov de tamanho variável*. Tese (Doutorado) — Instituto de Matemática e Estatística da Universidade de São Paulo, 12/04/2005., 2005.

17

NG, A. *Course of Machine Learning*. [S.l.], 2015. Disponível em:  
<<https://www.coursera.org/learn/machine-learning/>>.

14, 15

SANTOS, C. N. dos; ZADROZNY, B. Training state-of-the-art portuguese pos taggers without handcrafted features. In: *Computational Processing of the Portuguese Language*. [S.l.]: Springer, 2014. p. 82–93.

17

SHEN, L.; SATTA, G.; JOSHI, A. Guided learning for bidirectional sequence classification. In: CITESEER. *ACL*. [S.l.], 2007. v. 7, p. 760–767.

21

TURIAN, J.; RATINOV, L.; BENGIO, Y. Word representations: a simple and general method for semi-supervised learning. In: ASSOCIATION FOR COMPUTATIONAL LINGUISTICS. *Proceedings of the 48th annual meeting of the association for computational linguistics*. [S.l.], 2010. p. 384–394.

12

# Aprendizagem Guiada para Análise Morfossintática usando Redes Neurais Recursivas

Marcos Vinícius Treviso

`marcosvtreviso@gmail.com`

Orientador: Fábio Natanael Kepler

8 de julho de 2015

Universidade Federal do Pampa

# Redes neurais recursivas

- Grafo computacional parece como uma árvore
- Aplica-se transformações recursivamente
- Composição da saída com entrada

